Personal Data Cleaner

Обезличивание документов
в инфраструктуре компании



Продукт и технические возможности

a0nikolaevsoft@gmail.com

Персональные и конфиденциальные данные остаются в компании

Распознавание и обработка выполняются на ваших серверах. Документы не отправляются во внешние облачные сервисы.



Документы с ПДн усложняют ежедневную работу

Юридическая работа. Тестовые данные. Обмен с партнёрами.

Проблема процесса

Перед передачей документа командам приходится удалять персональные данные. Ручные правки требуют повторной проверки.

Возможность для продукта

Повторяемый процесс обработки в контуре компании с объяснением причин замен.

PDC создаёт рабочую копию без найденных ПДн

Загрузить файл или пакет. Найти ПДн. Применить правила замены. Скачать результат.

PDC.Desktop + PDC.Web

Windows-приложение и браузерный интерфейс для сотрудников. Интерфейс на русском и английском.

PDC.Server + API

Единая обработка, политики администратора и API для интеграций. Сервер работает в инфраструктуре компании.

Три варианта замены ПДн

Исходный документ

ФИО: Сергеев Павел
Телефон: +7 912 405-18-73
Проект: «Северный склад»

1. Замена на шаблон

ФИО: [TEMPLATE_FULLNAME]
Телефон: [TEMPLATE_PHONENUMBER]
Проект: «Северный склад»

2. Генерация данных

ФИО: Кузнецов Алексей
Телефон: +7 999 000-00-00
Проект: «Северный склад»

3. Совмещённый режим

ФИО: [TEMPLATE_FULLNAME]
Телефон: +7 999 000-00-00
Проект: «Северный склад»

Иллюстративные данные. Режимы замены можно сочетать по типам ПДн.

Первые клиенты: команды, передающие документы

Сегмент	Первый сценарий	Заказчик
Юристы и консалтинг	Документы для внешней проверки	Руководитель / ИТ
Разработка ПО	Примеры для QA и поддержки	Разработка / ИБ
Финансы и HR	Копии для подрядчиков	Бизнес / ИБ

Точка входа: один процесс, репрезентативные документы и ответственный владелец.

Позиционирование среди подходов

Подход	Что даёт	Что остаётся заказчику
Ручное удаление	Контроль специалиста	Повторение правок и проверок
Собственные скрипты	Свои правила	Форматы и сопровождение
Облачные сервисы	Готовая обработка	Передача данных и доступ
PDC	Файлы, локальные модели, UI и API	Развёртывание и проверка результата

Качественное сравнение подходов.

Продукт для работы внутри компании

1.15.12.5

Текущая версия в main

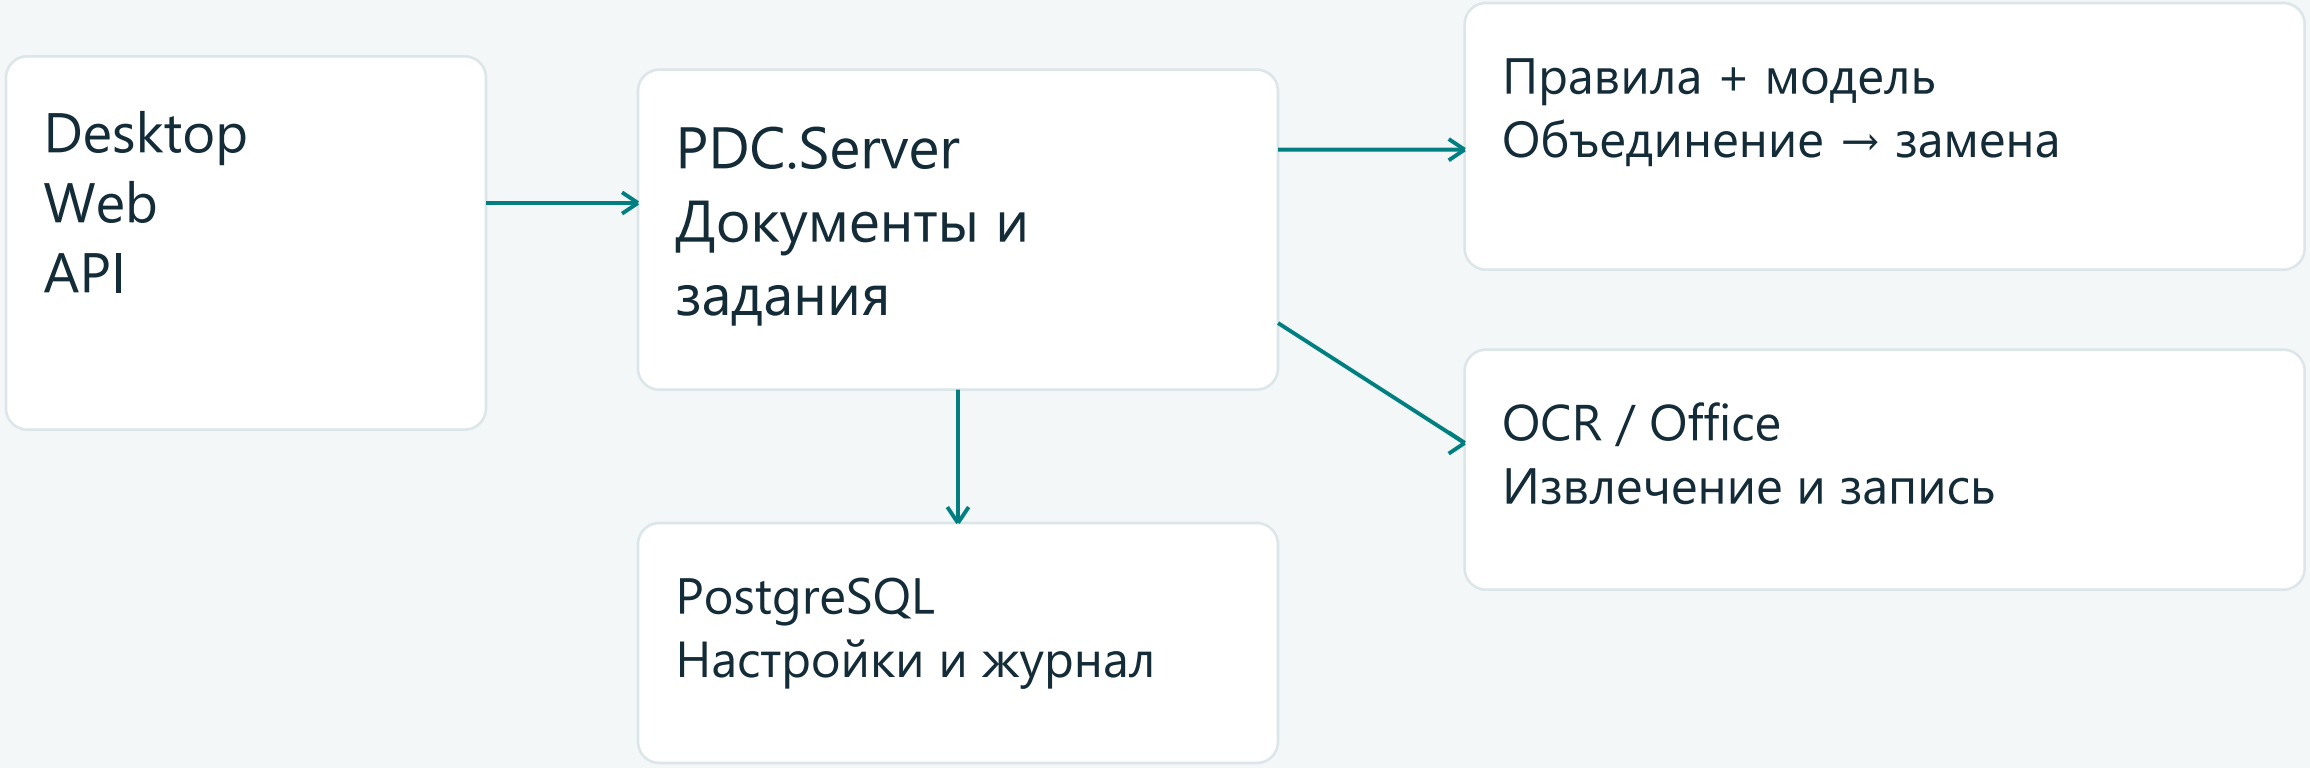
- Desktop — приложение Windows
- Web — работа через браузер
- API — файлы и фоновые пакеты
- Общие политики и причины замены
- Обработка на сервере организации

II

Технические спецификации

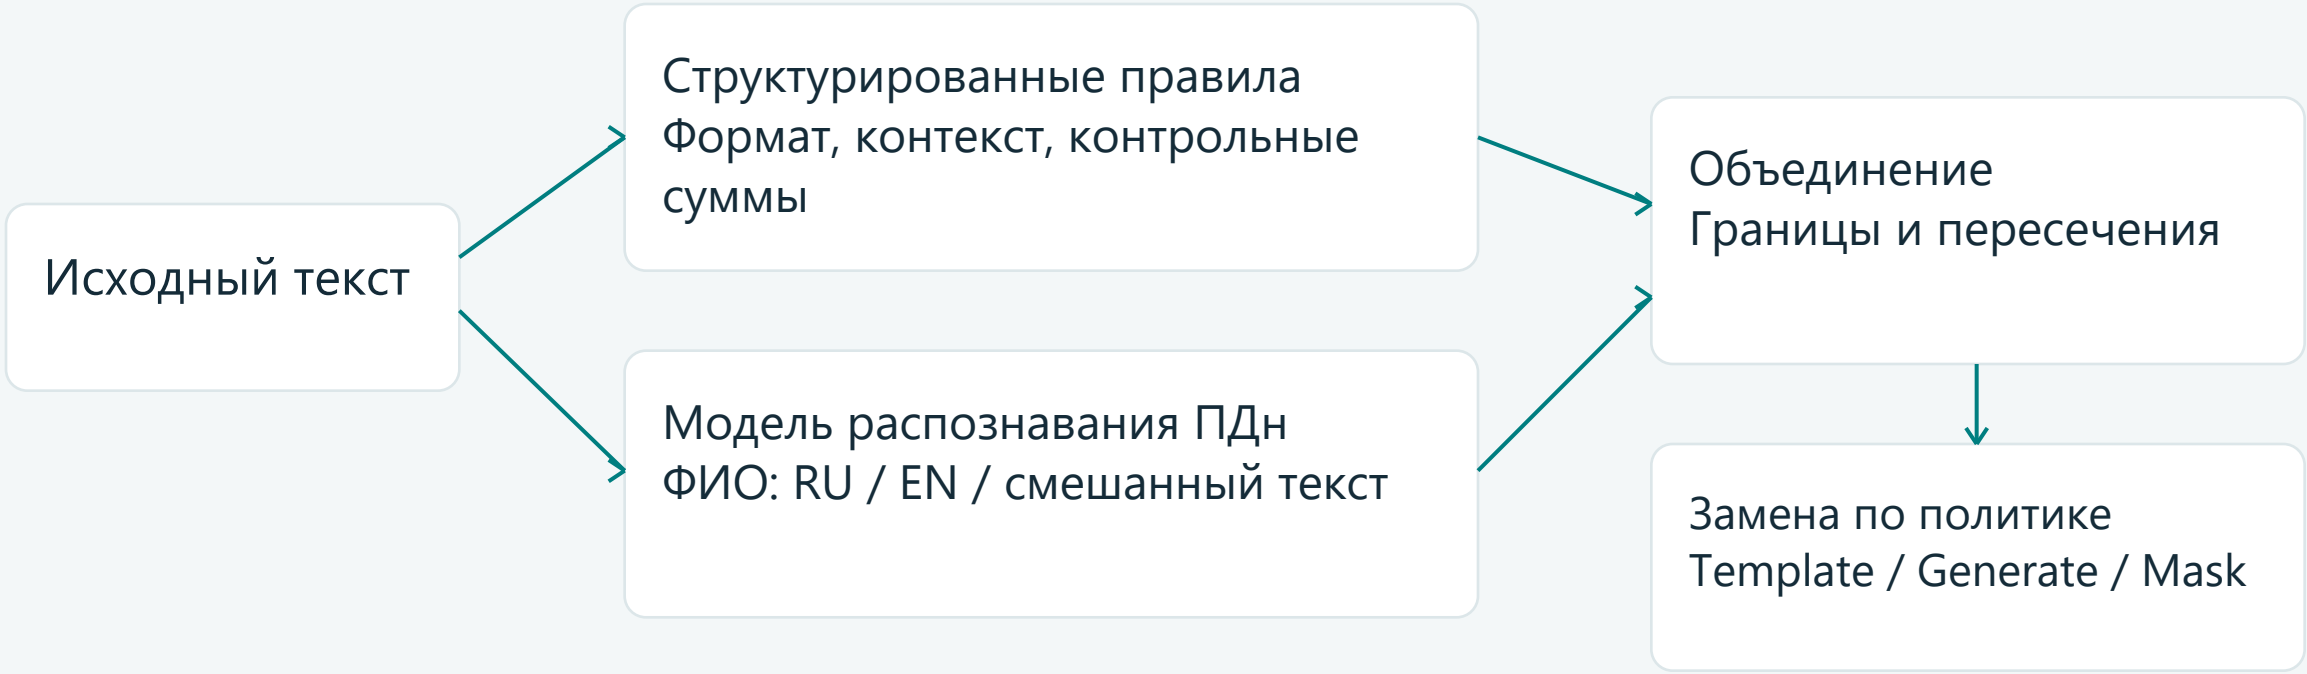
Архитектура, форматы, поставка и ограничения
Измеренные показатели и оставшиеся проверки.

Обработка в контуре компании



Клиенты передают файлы и получают результат. Данные, сервисы обработки и хранилище остаются в контуре компании.

Совместное распознавание ПДн



Обе проверки работают с исходным текстом до замены. Улучшены границы ФИО, инициалы и выбор полного имени при пересечении фрагментов.

Поддерживаемые форматы документов

Семейство	Форматы	Обработка
Office	DOCX, XLSX, PPTX	Обработчики Open XML
Старые Office	DOC, XLS, PPT	Преобразование через конвертер
PDF	Текст, сканы, смешанные PDF	Извлечение текста или OCR страниц
Текст	TXT, CSV	Замена в тексте
Изображения	PNG, JPG/JPEG, BMP, TIF/TIFF	OCR и замена пикселей

Сохранение вёрстки зависит от формата. Для PDF и конвертации есть ограничения.

Интеграция через файлы и фоновые задания

POST /api/documents/anonymize

Один файл multipart. Результат в HTTP-ответе.

POST /api/documents/batch

202 и ID задания. Опрос статуса, скачивание результата, удаление.
Для БД есть отдельный API заданий только для администратора.

Обработка баз данных с явными ограничениями

PostgreSQL / ClickHouse / SQL Server / Oracle

Реализованный объём

Выбранные текстовые столбцы одной таблицы. Новая таблица либо явное изменение исходной. Доступ Admin и список разрешённых адресов.

Условия эксплуатации

Перед in-place нужна резервная копия. Остановите внешнюю запись. Копия не переносит индексы, ограничения и права. В ClickHouse возможны частичные изменения.

Средства защиты и границы ответственности

Реализованные средства

JWT и роли User / Admin. Ограничения попыток входа. Web-сессии с HttpOnly refresh-cookie. Локальный инференс без публичного API модели.

Ответственность компании

HTTPS, секреты, доступ к хранилищам, резервные копии и сеть. Проверка остаточных идентификаторов и метаданных. Обработка не является сертификатом соответствия.

Исходные байты проходят через память сервера. Имена файлов, задания и причины замен могут храниться. Кэш результатов по умолчанию выключен.

Модели распознавания ПДн

Русский язык

Подготовлен экспериментальный кандидат. Новые веса проходят проверку перед включением в стандартную поставку.

Английский язык

По результатам испытаний сохранена исходная модель распознавания ПДн.

Исторический compact-кандидат не прошёл порог качества; он не заменяет стандартные модели.

Для добавления нового языка требуются дообучение модели и доработка регулярных выражений.

Compact: экономия в фиксированном протоколе

Проверка	default / 007	compact / 008
Пик working set в HTTP	8,868 GiB	1,097 GiB
CPU сервисов / успех HTTP	6 903,690 с; 516/530	454,929 с; 530/530
Тёплый RU TXT p50 / p95	2,481 / 2,912 с	0,031 / 0,051 с
Тёплый EN TXT p50 / p95	4,271 / 10,673 с	0,017 / 0,036 с

24 повтора/файл, C1. Те же файлы, ошибки сохранены. CPU при разном числе успехов. RAM без ОС/кэша; физический минимум compact не проверен.

Исторические бюджеты и планирование

Параметр	minimal / 005	standard / 004
Квота CPU / RAM	2 CPU / 10 GiB, swap 0	4 CPU / 12 GiB, swap 0
Пик working set	8,917 GiB по выборкам	8,718 GiB по выборкам
Ориентир для VM	2 vCPU / 16 GiB RAM	4 vCPU / 24 GiB RAM
Запас свободного SSD	40 GiB, планирование	60 GiB, планирование

Квоты не включают ОС/VM. Ориентиры VM/SSD — инженерная оценка. Minimal не снизил измеренный пик активной памяти.

Задержки и устойчивость под нагрузкой

Пример / проверка	standard	minimal
RU TXT p50 / p95	2,037 / 2,428 с	3,184 / 4,024 с
EN TXT p50 / p95	2,157 / 17,893 с	3,429 / 29,935 с
Контрольные HTTP	1 920 / 1 920 успехов	1 920 / 1 920 успехов
Внешние PDF / C8+	38/50; 102/144 успеха	34/50; 40/144 успеха

EN C1: 6,62–9,52 и 4,27–6,67 док/мин. Те же файлы, кэш результатов выключен. Начинать с C1; C8/16/48 — за пределами рабочего режима.

B3 / repeated C1 cohorts: 96 requests per file; v1.15.5.1

Запуск, простой и диск: архив

Проверка	standard	minimal
Готовность после рестарта	23,844–31,969 с	23,672–32,531 с
Первый документ	0,976–28,495 с; 12/12	1,132–50,328 с; 12/12
EN после 6 мин простоя	Остаётся загруженной (006)	Выгружена; загрузка 25,969 с
Inspect образов / тома моделей	5,661 GiB, сжатые данные	RU 2,648 / EN 2,027 GiB

Файлы моделей сохранены, кэш ОС не контролировался. Minimal: модель распознавания ПДн — 4,415 до 0,721 GiB после простоя. Inspect не включает распаковку; это не объём после установки.

Ограничения детекции и очистки

Проверки и измерения

Текущие исходники: 1 030 тестов. Замер v1.15.12.0: 3 308 текстов, ошибок вызова 0. Внешние типы: EN 76,24%, RU 89,54%. Внешние источники синтетические.

Выявленные ограничения

API, 22 файла: 20 результатов и 2 явных отказа. Авторы Office и миниатюры исправлены. Пропуски имён остаются: на 4 новых текстах одно имя не найдено.

Authenticode-подпись установщика Windows и произвольный каталог моделей остаются открытыми задачами.

Качество совместного распознавания

4 256 синтетических dev-текстов · модель + структурированные правила

Язык	Точность	Полнота	F1
RU	98,96%	100%	99,48%
EN	100%	100%	100%
RU + EN	98,96%	100%	99,48%

27 792 найденных вхождения · 0 пропусков · 240 лишних срабатываний

Расчёт по точным сохранённым ответам моделей на собственном dev-наборе. Это не доля полностью очищенных документов и не гарантия для новых файлов, Office, PDF или OCR.